

Метод максимального правдоподобия

Θ

1) фокус работает раз в год

$1/365$



2) фокус работает только эти недели

$7/365$

3) всегда

1

$x_1 = \text{фокус. час.}$

$P(x_1 = \text{фокус.} | \theta = \text{интенс.})$

Упражнение

$X_1, \dots, X_n \sim \text{iid Poiss}(\lambda)$

$$P(X=k) = \frac{e^{-\lambda} \cdot \lambda^k}{k!}$$

$$L(\lambda) = P(X_1, \dots, X_n | \lambda) = P(X_1 | \lambda) \cdot \dots \cdot P(X_n | \lambda) \rightarrow \max_{\lambda}$$

$$L(\lambda) = \frac{e^{-n\lambda} \cdot \lambda^{\sum x_i}}{x_1! \cdot x_2! \cdot \dots \cdot x_n!} \rightarrow \max_{\lambda}$$

$$L(\lambda) \propto e^{-n\lambda} \cdot \lambda^{\sum x_i}$$

$$\ln L(\lambda) \propto -n\lambda + \sum x_i \cdot \ln \lambda$$

$$\frac{\partial \ln L(\lambda)}{\partial \lambda} = -n + \frac{\sum x_i}{\lambda} = 0 \Rightarrow \hat{\lambda}_{ML} = \bar{x}$$

$$\frac{\partial^2 \ln L(\lambda)}{\partial \lambda^2} = -\frac{\sum x_i}{\lambda^2}$$

$$\hat{\lambda}_{ML} \stackrel{\text{asy}}{\sim} \mathcal{N}(\lambda; \frac{\lambda}{n})$$

$$-\mathbb{E}\left(-\frac{\sum x_i}{\lambda^2}\right) = \frac{1}{\lambda^2} \mathbb{E}(\sum x_i) = \frac{n\lambda}{\lambda^2} = \frac{n}{\lambda} \rightarrow \text{CI}$$

\rightarrow интеграл

Свойства:

- 1) $\hat{\theta}^{\text{ML}} \xrightarrow{P} \theta$ со свойством
- 2) Оценка н.з. симметрична, то она асимм. несимм.
- 3) Асимм. эффи.
- 4) $\hat{\theta}^{\text{ML}} \xrightarrow{\text{asy}} N(\theta, \hat{I}^{-1}(\theta))$

инт. Фишер

бескрайний

$$\frac{n}{d} \rightarrow \infty \quad I(\theta) = -\mathbb{E}\left(\frac{\partial^2 \ln L}{\partial \theta_i \partial \theta_j}\right) = -\mathbb{E}(H)$$

- 5) $\begin{array}{c} \theta \\ \uparrow \\ \hat{\theta}^{\text{ML}} \end{array} \quad \lambda = g(\theta) \quad \text{инвариантность}$
- $\hat{\lambda} = g(\hat{\theta}^{\text{ML}})$


Это всё работает для распределений, у которых выполнены условия регулярности:

- Нормально берутся производные $f'_x(t)$
- Обл. опр. сл. вен. не заб. от параметра

То есть второй производной отвечают за дисперсию?

$$\ln L(\theta | x_1, \dots, x_n) = \sum_{i=1}^n \ln f(x_i; \theta) \rightarrow \max_{\theta} P(x_i; \theta)$$

$$\frac{\partial \ln L}{\partial \theta} = \sum_{i=1}^n \frac{\partial \ln f(x_i; \theta)}{\partial \theta} = 0$$



$$L(\theta | x_i) = \ln f(x_i | \theta)$$

1 набор.

10 набор

$$L(\theta | x_1, \dots, x_{10}) = \sum_{i=1}^{10} \ln f(x_i | \theta)$$

θ

мат. ожидание:

$f'(x)$ отвечает
за выпуклость

$$I_{\text{obs.}}(\theta) = -\frac{\partial^2 \ln L}{\partial \theta} = -H$$

коэффициент кр. Фишера

Чем выпуклее \uparrow . Там больше
нормализации

$$I(\theta) = \mathbb{E}(-H)$$

считаемый кр. Фишера

$$\hat{I}(\theta)$$

$$\rightarrow \hat{I}(\theta) = -\mathbb{E}(H) \Big|_{\theta=\hat{\theta}}$$

$$\rightarrow \hat{I}(\theta) = -H \Big|_{\theta=\hat{\theta}}$$

$$\rightarrow \hat{I}(\theta) = \mathbb{E}\left(\left[\frac{\partial \ln L}{\partial \theta}\right] \cdot \left[\frac{\partial \ln L}{\partial \theta}\right]^T\right) \Big|_{\theta=\hat{\theta}}$$

Если функция логарифмическая, то градиент коэффициента:

$$-\mathbb{E} \left(\frac{\partial^2 L}{\partial \theta^2} \right) = \mathbb{E} \left(\left[\frac{\partial \ln L}{\partial \theta} \right] \cdot \left[\frac{\partial \ln L}{\partial \theta} \right]^T \right)$$

Упоминание

m & s	X	Красивый	менее красивый	Случай
		P_1	P_2	$1 - P_1 - P_2$

$$n = 100$$

$$X_1 - \text{красивый}$$

$$X_2 - \text{менее красивый}$$

$$X_1 \sim \text{Bin}(P_1, n)$$

$$X_2 \sim \text{Bin}(P_2, n)$$

$$X_3 \sim \text{Bin}(P_3, n)$$

$$X_1 + X_2 + X_3 = n$$

$$L \propto P_1^{X_1} \cdot P_2^{X_2} \cdot (1 - P_1 - P_2)^{n - X_1 - X_2} \rightarrow \max_{P_1, P_2} L$$

$$\ln L \propto X_1 \ln P_1 + X_2 \ln P_2 + (n - X_1 - X_2) \ln (1 - P_1 - P_2)$$

$$\begin{cases} \frac{\partial \ln L}{\partial P_1} = \frac{X_1}{P_1} - \frac{n - X_1 - X_2}{1 - P_1 - P_2} = 0 \\ \frac{\partial \ln L}{\partial P_2} = \frac{X_2}{P_2} - \frac{n - X_1 - X_2}{1 - P_1 - P_2} = 0 \end{cases} \quad \begin{cases} \hat{P}_1 = \frac{X_1}{n} \\ \hat{P}_2 = \frac{X_2}{n} \end{cases}$$

$$H = \begin{pmatrix} -\frac{X_1}{P_1^2} - \frac{n - X_1 - X_2}{(1 - P_1 - P_2)^2} & -\frac{n - X_1 - X_2}{(1 - P_1 - P_2)^2} \\ -\frac{n - X_1 - X_2}{(1 - P_1 - P_2)^2} & -\frac{X_2}{P_2^2} - \frac{n - X_1 - X_2}{(1 - P_1 - P_2)^2} \end{pmatrix} \quad \mathbb{E}(H) = \begin{pmatrix} -\frac{n}{P_1} - \frac{n}{1 - P_1 - P_2} & -\frac{n}{1 - P_1 - P_2} \\ -\frac{n}{1 - P_1 - P_2} & -\frac{n}{P_2} - \frac{n}{1 - P_1 - P_2} \end{pmatrix}$$

$$\mathbb{E} \left(-\frac{n - X_1 - X_2}{(1 - P_1 - P_2)^2} \right) = -\frac{n - \mathbb{E}(X_1) - \mathbb{E}(X_2)}{(1 - P_1 - P_2)^2} = \frac{n - nP_1 - nP_2}{(1 - P_1 - P_2)^2} =$$

$$= -\frac{n(1 - P_1 - P_2)}{(1 - P_1 - P_2)^2}$$

$$\text{Cov}(\hat{P}_1, \hat{P}_2) < 0$$

$$\hat{I}(P) = -\mathbb{E}(H) \Big|_{P=\hat{P}}$$

$$\hat{\text{Var}}(P) = [\hat{I}(P)]^{-1} = \begin{bmatrix} \hat{\text{Var}}(\hat{P}_1) \hat{\text{Cov}}(\hat{P}_1, \hat{P}_2) \\ \hat{\text{Cov}}(\hat{P}_1, \hat{P}_2) \hat{\text{Var}}(\hat{P}_2) \end{bmatrix}$$

$$\hat{P}_2 - \hat{P}_1 \pm \sum_{1-\alpha} \sqrt{\hat{\text{Var}}(\hat{P}_1) + \hat{\text{Var}}(\hat{P}_2) - 2 \text{Cov}(\hat{P}_1, \hat{P}_2)}$$

Можно ли сформулировать Δ -метод

$$\hat{\theta} \xrightarrow{\text{asy}} N(\theta, \hat{\text{Var}}(\hat{\theta}))$$

$$g(\hat{\theta}) \xrightarrow{\text{asy}} N(g(\theta); \nabla g^T \cdot \hat{\text{Var}}(\hat{\theta}) \cdot \nabla g)$$

А что делать, если у нас есть предположение о форме?

$$X_1, \dots, X_n \sim \text{iid } U[0; \theta] \quad f_X(x) = \begin{cases} \frac{1}{\theta}, & x \in [0; \theta] \\ 0, & \text{else} \end{cases}$$

$$L = \frac{1}{\Theta} \cdot \frac{1}{\Theta} \cdots \frac{1}{\Theta} = \frac{1}{\Theta^n} \rightarrow \max_{\Theta}$$

$$\ln L = -n \ln \Theta$$

$$x_1, \dots, x_n \leq \Theta$$

$$(\ln L)'_{\Theta} = -\frac{n}{\Theta} = 0 \quad \emptyset$$

$$x_{\max} \leq \Theta$$

$$\Theta \uparrow \Rightarrow L \downarrow$$

$$\hat{\Theta} = x_{\max}$$

А нын рөзгүл түгэж МО?


$$x \quad y \quad y = \langle w, x \rangle \quad \rightarrow L(y_i, \hat{y}_i) = (y_i - \hat{y}_i)^2$$

$$\text{бүрдүрка} \quad \hat{y} = \langle \hat{w}, x \rangle \quad \rightarrow L(y_i, \hat{y}_i) = |y_i - \hat{y}_i|$$

w-нормалт


$$Q = \frac{1}{n} \sum_{i=1}^n L(y_i, \hat{y}_i) \rightarrow \min_w$$

$$\rightarrow \text{Функция}$$




\rightarrow Log Cosh

Error rate



$$M_i = y_i \cdot \langle w, x_i \rangle$$

$$\sum_{i=1}^n \{ \}$$



Чине керхийн
ногхыг

Мальтернатива: вероятностный подход

$$y, x \quad y = \langle w, x \rangle + \varepsilon$$

$$\varepsilon \sim \mathcal{N}(0, \sigma^2)$$

$$\underline{y|x} \sim \mathcal{N}(\langle w, x \rangle, \sigma^2)$$

На данные наложено вер. п.-е.

$$f(t) = \frac{1}{\sqrt{2\pi\sigma^2}} \cdot \exp\left(-\frac{(x-t)^2}{2\sigma^2}\right)$$

$$L(w|x, y) = P(y|x, w) = P(y_1|x_1, w) \cdot \dots \cdot P(y_n|x_n, w) =$$

$$= \left(\frac{1}{\sqrt{2\pi\sigma^2}} \right)^n \cdot \exp\left(-\frac{\sum (y_i - \langle w, x_i \rangle)^2}{2\sigma^2}\right) \rightarrow \max_w$$

$$\ln L = -\frac{n}{2} \ln 2\pi\sigma^2 - \frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - \langle w, x_i \rangle)^2 \rightarrow \max_w$$

На σ^2 навигу

$$-\sum_{i=1}^n (y_i - \langle w, x_i \rangle)^2 \rightarrow \max_w \left(x - \frac{1}{n} \right)$$

$$-\ln L \propto \text{MSE} \quad \frac{1}{n} \sum_{i=1}^n (y_i - \langle w, x_i \rangle)^2 \rightarrow \min_w$$

Гипер几何

$$P(y_i | x_i) = \frac{e^{-\lambda(x_i)} \cdot \lambda(x_i)^{y_i}}{y_i!}$$

$$\lambda(x_i) = \exp(\langle w, x_i \rangle) \quad \text{То есть логистическая вероятность}$$

$$\lambda(x_i) = \exp(a(x_i)) \quad a(x_i) = \beta_0 + \beta_1 x_i$$

$$L(w) \propto e^{-\sum \lambda(x_i)} \cdot \lambda(x_1) \cdot \dots \cdot \lambda(x_n)$$

$$\ln L(w) \propto -\sum \lambda(x_i) + \sum y_i \ln \lambda(x_i)$$

$$\text{PoisLoss} = \frac{1}{n} \sum \lambda(x_i) - y_i \ln \lambda(x_i) \rightarrow \min_w$$

