

Мощь средних v. 2.0


① Асимптотические г.ч.

$X_1, \dots, X_n \sim \text{iid} (\mu, \sigma^2)$ $\sigma^2 < \infty$ Big data
и большое

$$\hat{\mu} = \bar{X}_n \stackrel{\text{asy}}{\sim} \mathcal{N}(\mu, \frac{\sigma^2}{n})$$

$$\bar{X}_n \stackrel{\text{asy}}{\sim} \mathcal{N}(\mu, \frac{\hat{\sigma}^2}{n})$$

Хоту понять между какими $\hat{\mu}^L$ и $\hat{\mu}^R$ лежит μ

$$Z = \frac{\bar{X}_n - \mu}{\sqrt{\hat{\sigma}^2/n}} \stackrel{\text{asy}}{\sim} \mathcal{N}(0, 1)$$



$$P\left(-Z_{1-\frac{\alpha}{2}} \leq \frac{\bar{X}_n - \mu}{\hat{\sigma}/\sqrt{n}} \leq Z_{1-\frac{\alpha}{2}}\right) = 1 - \alpha$$

$$P\left(\underbrace{\bar{X}_n - Z_{1-\frac{\alpha}{2}} \cdot \frac{\hat{\sigma}}{\sqrt{n}}}_{\hat{\mu}^L} \leq \mu \leq \underbrace{\bar{X}_n + Z_{1-\frac{\alpha}{2}} \cdot \frac{\hat{\sigma}}{\sqrt{n}}}_{\hat{\mu}^R}\right) = 1 - \alpha$$



$[\hat{\mu}^L; \hat{\mu}^R]$ накрывает центр. зн. μ с вер. $1 - \alpha$
⊕ самый короткий

Почему самый короткий интервал симметричный?

идея 501:



угея 502:



$f(t)$ - плотность р.-р.

$\gamma = 1 - \alpha \in (0, 1)$

$[a, b]$ - интервал максимальной густоты из тех, для

которых $\int_a^b f(t) dt = 1 - \alpha$

Докажем, что всегда $f(a) = f(b)$ если $\exists$ такие

$$\begin{cases} b-a \rightarrow \min_{b,a} \\ \int_a^b f(t) dt = \gamma \end{cases}$$

$$F(b) - F(a) = \gamma$$

гоустные
точки

$$\mathcal{L} = (b-a) + \lambda \cdot (F(b) - F(a) - \gamma)$$

$$\frac{\partial \mathcal{L}}{\partial a} = -1 - \underbrace{F'(a)}_{f(a)} \cdot \lambda = 0$$

сложим
у р.-р.


$$\frac{\partial \mathcal{L}}{\partial b} = 1 + \underbrace{F'(b)}_{f(b)} \cdot \lambda = 0$$

$$\lambda = -\frac{1}{f(b)} \neq 0$$

$$f(b) > 0$$

$$\lambda \cdot (f(b) - f(a)) = 0$$

$$f(b) = f(a) \quad \blacksquare$$



Доб. укт., где нет двух точек

② Д.ч. для голей

$$X_1, \dots, X_n \sim \text{iid Bern}(p)$$

$$\mu = \mathbb{E}(X_i) = p$$

X_i	0	1
	$1-p$	p

$$\sigma^2 = \text{Var}(X_i) = p(1-p)$$

$$\hat{p} = \bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$$

$$\mathbb{E}(\hat{p}) = \mu = p$$

$$\text{Var}(\hat{p}) = \frac{\sigma^2}{n} = \frac{p(1-p)}{n}$$

$$\hat{p} \overset{\text{asy}}{\sim} \mathcal{N}\left(p, \frac{\hat{p}(1-\hat{p})}{n}\right)$$

CI для p :

$$\hat{p} \pm z_{1-\frac{\alpha}{2}} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}$$

$$X_1, \dots, X_{n_x} \sim \text{iid Bern}(p_x)$$

$$Y_1, \dots, Y_{n_y} \sim \text{iid Bern}(p_y)$$

нез. друг от друга

$$\hat{p}_x \overset{\text{asy}}{\sim} \mathcal{N}\left(p_x, \frac{\hat{p}_x(1-\hat{p}_x)}{n_x}\right)$$

$$\hat{p}_y \overset{\text{asy}}{\sim} \mathcal{N}\left(p_y, \frac{\hat{p}_y(1-\hat{p}_y)}{n_y}\right)$$

независимые
сл. вел.

$$\begin{pmatrix} \hat{P}_x \\ \hat{P}_y \end{pmatrix} \stackrel{asy}{\sim} \begin{pmatrix} P_x \\ P_y \end{pmatrix} \begin{pmatrix} \frac{\hat{P}_x(1-\hat{P}_x)}{n_x} & 0 \\ 0 & \frac{\hat{P}_y(1-\hat{P}_y)}{n_y} \end{pmatrix}$$

$$\hat{P}_y - \hat{P}_x \stackrel{asy}{\sim} \begin{pmatrix} P_y - P_x; \frac{\hat{P}_x(1-\hat{P}_x)}{n_x} + \frac{\hat{P}_y(1-\hat{P}_y)}{n_y} \end{pmatrix}$$

L - ур. значимости

$$P_y - P_x \quad \hat{P}_y - \hat{P}_x \pm Z_{1-\frac{L}{2}} \cdot \sqrt{\frac{\hat{P}_x(1-\hat{P}_x)}{n_x} + \frac{\hat{P}_y(1-\hat{P}_y)}{n_y}}$$


$H_0: P_y = P_x \leftarrow$ Если 0 покрыт до в. ил.

$H_A: P_y \neq P_x \leftarrow$ иначе

Проведем АБ-тест через г.и.

③ NPS

Net Promoter Score



детракторы


D

нейтралы

N

промоутер

L



$X_1, \dots, X_n \sim iid$ мультиномиальное распределение

$$D + N + L = n$$

$$NPS = P_L - P_D$$

$$P_D + P_N + P_L = 1$$

$$\text{cov}(P_L, P_D) < 0$$

зависимы

$$\hat{NPS} = \hat{P}_L - \hat{P}_D \quad \hat{NPS} \stackrel{asy}{\sim} ? \quad CI \text{ на } NPS ?$$

$$\begin{pmatrix} \hat{P}_L \\ \hat{P}_D \end{pmatrix} \stackrel{asy}{\sim} \mathcal{N} \left(\begin{pmatrix} P_L \\ P_D \end{pmatrix}; \begin{pmatrix} \frac{\hat{P}_L(1-\hat{P}_L)}{n} & -\frac{\hat{P}_L\hat{P}_D}{n} \\ -\frac{\hat{P}_L\hat{P}_D}{n} & \frac{\hat{P}_D(1-\hat{P}_D)}{n} \end{pmatrix} \right)$$

$$\text{Var}(\hat{P}_L - \hat{P}_D) = \text{Var}(\hat{P}_L) + \text{Var}(\hat{P}_D) - 2 \cdot \text{Cov}(\hat{P}_L, \hat{P}_D)$$

$$CI \text{ на } NPS: \hat{P}_L - \hat{P}_D \pm z_{1-\frac{\alpha}{2}} \cdot \sqrt{\frac{\hat{P}_L(1-\hat{P}_L)}{n} + \frac{\hat{P}_D(1-\hat{P}_D)}{n} + 2 \cdot \frac{\hat{P}_L\hat{P}_D}{n}}$$

$$\text{Cov}(\hat{P}_L, \hat{P}_D) = \text{Cov}\left(\frac{L}{n}; \frac{D}{n}\right) = \frac{1}{n^2} \cdot \text{Cov}(L, D)$$

$$\underbrace{L + D + N}_{const} = n \quad \text{Cov}(x, const) = 0$$

$$\text{Cov}(L + D + N, D) = 0$$

$$\underbrace{\text{Cov}(L, D)}_{C_{LD}} + \underbrace{\text{Cov}(D, D)}_{\text{Var}(D)} + \underbrace{\text{Cov}(N, D)}_{C_{ND}} = 0$$

Три ур.-я, три
переменные

$$n \cdot P_D(1-P_D) \leftarrow \text{это}$$

$$\begin{cases} V_D + C_{LD} + C_{ND} = 0 \\ V_L + C_{LD} + C_{LN} = 0 \\ V_N + C_{LN} + C_{ND} = 0 \end{cases} \Leftrightarrow \dots \quad C_{LD} = \frac{-V_D + V_N \cdot V_L}{2} = -n P_L P_D$$

↑
Все сгруппировано
и это

④ Конечная генеральная совокупность

$x_1, \dots, x_N$ - вся ген. сов. и σ^2

$X_1, \dots, X_n$ - выборка без повторений

x_1, x_2, x_3, x_4
m k c

X_1, X_2
m k
j c
c m

X_i	1	2	3	4
$P(\dots)$	$1/4$	$1/4$	$1/3$	$1/4$

$$P(X_1 = m) \cdot P(X_2 = m) \neq P(X_1 = m \cap X_2 = m) = 0$$

$1/4 \quad 1/4$

сл. вел. зависимые

$$\text{Cov}(X_1, X_2) < 0$$

$X_1 + X_2 + \dots + X_N = \text{const}$, не случайная вел.

$$\text{Cov}(X_1 + \dots + X_N, X_i) = 0$$

$$\text{Var}(X_i) + (N-1) \cdot \text{Cov}(X_i, X_j) = 0 \quad i \neq j$$

$$\text{Cov}(X_i, X_j) = -\frac{\text{Var}(X_i)}{N-1} = -\frac{\sigma^2}{N-1} < 0$$

Выборка не iid

$\mu \quad \bar{X}_n \quad n < N$

$$E(\bar{X}_n) = E\left(\frac{X_1 + \dots + X_n}{n}\right) = \frac{1}{n} (E(X_1) + \dots + E(X_n)) = \mu$$

$$\text{Var}(\bar{X}_n) = \frac{1}{n^2} (\text{Var}(X_1) + \dots + \text{Var}(X_n) + 2\text{Cov}(X_1, X_2) + \dots + 2\text{Cov}(\dots))$$

$$= \frac{1}{n^2} \left(n \cdot \sigma^2 + \frac{n(n-1)}{2} \cdot 2 \cdot \left(-\frac{\sigma^2}{N-1} \right) \right) =$$

$$= \frac{1}{n} \cdot \left(\sigma^2 - \frac{(n-1)}{(N-1)} \sigma^2 \right) = \left(1 - \frac{n-1}{N-1} \right) \cdot \frac{\sigma^2}{n}$$

$\frac{\sigma^2}{2}$ - будет ковариацией

поправка на
конечную зем. сов.

$$n \ll N \quad \frac{n}{N} \approx 0$$

В мире Big Data эта поправка близка к 1.