


Критерии согласия и однородности



① Критерий Колмогорова (1 выборка)


Проверяем гипотезу о конкретном распределении.

$$H_0: X \sim F_X(t)$$

$$H_0: F_X(t) = F_0(t)$$

$$H_A: X \sim \text{другое}$$

$$H_A: F_X(t) \neq F_0(t)$$



$$X_1, \dots, X_n \sim iid$$

$$\hat{F}_n(t) = \hat{P}(X \leq t) = \frac{1}{n} \sum_{i=1}^n [X_i \leq t]$$

Если H_0 выполняется, тогда расстояние между $F_0(t)$ и $\hat{F}_n(t)$ маленькое.

Разные критерии $\Rightarrow$ разные расстояния

$$D_n = \sup_t |F_0(t) - \hat{F}_n(t)|$$

статистика
Колмогорова

$$K_n = \sqrt{n} \cdot D_n \underset{H_0}{\sim} \text{p.-e. Колмогорова}$$

$\forall$ непрерывных
распределений

Критерий Колмогорова:

$$X_1, \dots, X_n \sim \text{iid } F_X(t)$$

$$H_0: F_X(t) = \mathcal{N}(0, 1)$$

$$H_A: \neq$$



$$K_{obs} \text{ vs } K_{1-\alpha}$$

Другие критерии:

$$\int \Psi(F_0(t)) \cdot (F_0(t) - \hat{F}_n(t))^2 \cdot f_0(t) dt \underset{H_0}{\sim} \text{известное p.-e.}$$

$$\Psi(F_0(t)) = 1 \quad \text{Критерий Крамера-Уизеса}$$

$$\Psi(F_0(t)) = \frac{1}{F_0(t) \cdot (1 - F_0(t))} \quad \text{Критерий Андерсона-Дарлингса}$$



Важнее разница
в хвостах
распределения

② Критерий Колмогорова-Смирнова (KS-test)

Проверяем гипотезу об однородности выборок

$$X_1^T, \dots, X_{n_T}^T \sim \text{iid } F_T(t)$$

$$X_1^c, \dots, X_{n_c}^c \sim \text{iid } F_c(t)$$

$$H_0: F_T(t) = F_c(t)$$




$$H_A: \neq$$

$$KS = \sqrt{\frac{n_T \cdot n_c}{n_T + n_c}} \cdot \sup_t |\hat{F}_c(t) - \hat{F}_T(t)| \underset{H_0}{\sim}^{asy} \text{p.-e. Колмогорова-Смирнова}$$


$$n_T \rightarrow \infty$$

$$n_c \rightarrow \infty$$

KS_{obs} vs $KS_{1-\alpha}$



KS-тест понимает все эти измерения



А что делать с дискретными распределениями

③ Критерий Пирсона

$$H_0: F_X(t) = F_0(t)$$

$$H_A: F_X(t) \neq F_0(t)$$

$$X_1, \dots, X_n \sim \text{iid } F_X(t)$$

X	x_1	x_2	...	x_s
	$P_1(\theta)$	$P_2(\theta)$	...	$P_s(\theta)$
	ϑ_1	ϑ_2	...	ϑ_s

— возможные значения

— теор. вероятности

$$\frac{e^{-\theta} \cdot \theta^k}{k!}$$

частоты по выборке
по клеткам

$$\sum_{j=1}^s \frac{(\vartheta_j - n \cdot P_j(\hat{\theta}))^2}{n \cdot P_j(\hat{\theta})} \underset{H_0}{\sim} \chi^2_{s-k-1}$$

θ
[k x 1]

k - число параметров

$$\chi^2_{s-k-1} (1-\alpha) \quad \text{vs} \quad \chi^2_{obs}$$

④ Критерий χ^2 для однородности

$$X_1^c, \dots, X_{n_c}^c \sim \text{iid } F_c(t)$$

$$X_1^T, \dots, X_{n_T}^T \sim \text{iid } F_T(t)$$

$$H_0: F_T(t) = F_c(t)$$

$$H_A: \neq$$

	z_1	z_2	...	z_s
T	ϑ_1	ϑ_2	...	ϑ_s
C	w_1	w_2	...	w_s

частоты

$$\sum_{j=1}^s \frac{\left(\frac{\vartheta_j}{n_T} - \frac{w_j}{n_C} \right)^2}{\frac{1}{n_T} + \frac{1}{n_C}} \underset{H_0}{\sim} \chi^2_{s-1}$$

⑤ Тест χ^2 на нез. выборки

X \ Y	да	нет	
взяла	7	1	8
нет	1	11	12
	8	12	

$$P(X=x \cap Y=y) = P(X=x) \cdot P(Y=y)$$

$$\frac{\sum [X_i = x \cap Y_j = y]}{n} = \frac{\vartheta_{ij}}{n}$$

$$\frac{\sum [X_i = x]}{n} = \frac{\vartheta_{i.}}{n}$$

$$\frac{\sum [Y_j = y]}{n} = \frac{\vartheta_{.j}}{n}$$

H_0 : X и Y нез. (дискриминация нет)

H_A : зависимы

$$PF = \sum_{i,j} \frac{\left(n \cdot \left[\frac{\partial_{ij}}{n} - \frac{\partial_{i\cdot}}{n} \cdot \frac{\partial_{\cdot j}}{n} \right] \right)^2}{n \cdot \frac{\partial_{i\cdot}}{n} \cdot \frac{\partial_{\cdot j}}{n}} \underset{H_0}{\stackrel{asy}{\sim}} \chi^2_{(k-1)(s-1)}$$

k - кол-во значений X

s - кол-во значений Y

1900 - 1915 Пирсон

$$PF \xrightarrow{d} \chi^2_{k-s-1}$$

1915 - н.в. Фишер

$$PF \xrightarrow{d} \chi^2_{(k-1)(s-1)}$$