


Критерии согласия и однородности

Данные $\rightarrow$ пакеты
 $\rightarrow$ знаки

~~MW-test~~



KS-test либо Bootstrap

① Критерий Колмогорова (1 выборка)


Проверяет гипотезу о конкретном распределении для одной выборки.

$$H_0: X \sim F_X(t)$$

$$H_0: F_X(t) = F_0(t)$$

$$H_A: X \sim \text{другое}$$

$$H_A: F_X(t) \neq F_0(t)$$



$$X_1, \dots, X_n \sim iid$$

$$\hat{F}_n(t) = \hat{P}(X \leq t) = \frac{1}{n} \sum_{i=1}^n [X_i \leq t]$$

Если H_0 выполняется, тогда расстояние между $F_0(t)$ и $\hat{F}_n(t)$ маленькое

Разные
расстояния

$\Rightarrow$

разные
критерии

Опр.

Статистика
Колмогорова

$$D_n = \sup_t |F_0(t) - \hat{F}_n(t)|$$

$$K_n = \sqrt{n} \cdot D_n \underset{H_0}{\overset{asy}{\rightsquigarrow}} \text{p.-e. Колмогорова}$$

✓ непрерывных
распределений

Критерий Колмогорова:

$$X_1, \dots, X_n \sim iid F_X(t)$$

$$H_0: F_X(t) = U(0, 1) \leftarrow \text{фиксир. параметры}$$

$$H_A: \neq$$

Если оценивать
параметры по
выборке
распределение
будет другим

$$K_{obs} \text{ vs } K_{1-\alpha}$$


Другие критерии:

$$\int \Psi(F_0(t)) (F_0(t) - \hat{F}_n(t))^2 \cdot f_0(t) dt \underset{H_0}{\rightsquigarrow} \text{p.-e.}$$

известно
p.-e.

$\Psi(F_0(t)) = 1$ Критерий Крамера-Мизеса

$\Psi(F_0(t)) = \frac{1}{F_0(t)(1-F_0(t))}$ Критерий Андерсона-Дарлингса



Важнее разница в хвостах распределения

② Критерий Колмогорова-Смирнова (KS-test)

Проверяем гипотезу об однородности выборок

$$X_1^T, \dots, X_{n_T}^T \sim \text{iid } F_T(t)$$

$$X_1^c, \dots, X_{n_c}^c \sim \text{iid } F_c(t)$$

$$\sqrt{n} \cdot (\bar{X} - \mu) \overset{\text{asy}}{\sim} \mathcal{N}(0, \sigma^2)$$


$$H_0: F_T(t) = F_c(t)$$


$$H_A: \neq$$

$$KS = \sqrt{\frac{n_T \cdot n_c}{n_T + n_c}} \cdot \sup_t |\hat{F}_c(t) - \hat{F}_T(t)| \overset{\text{asy}}{\underset{H_0}{\sim}} \text{P. e. Колмогорова-Смирнова}$$

$$n_T \rightarrow \infty$$

$$n_c \rightarrow \infty$$





KS-test понимает все эти изменения

Важно:

- выборки i.i.d + незав. друг от друга
- распределения непрерывные
- на выбросы кофизу

А что делать если распределения дискретные?

③ Критерий Пирсона

$$H_0: F_x(t) = F_0(t)$$

$$H_A: F_x(t) \neq F_0(t)$$

$$X_1, \dots, X_n \sim \text{i.i.d}$$

дискретная

X	x_1	x_2	...	x_s
	$P_1(\theta)$	$P_2(\theta)$	...	$P_s(\theta)$
	$\hat{p}_1$	$\hat{p}_2$	...	$\hat{p}_s$

- возможные значения

- теоретические вер-ти

$$\frac{e^{-\theta} \cdot \theta^k}{k!}$$

частоты

полученные

по выборке

счит (*)

$$\hat{p}_j = n \cdot \hat{P}_j \underset{H_0}{\sim} \chi^2_{(n p_j; n p_j(1-p_j))} [\chi^2(0; n p_j(1-p_j))]^2$$

$$\sum_{j=1}^S \frac{(\mathcal{V}_j - n P_j(\hat{\theta}))^2}{n P_j(\hat{\theta})} \underset{H_0}{\sim}^{asy} \chi_{S-k-1}^2$$

k - число параметров $\hat{\theta}_{[k+1]}$

$$\chi_{S-k-1}^2 (1-\alpha) \text{ vs } \chi_{obs}^2$$

④ Критерий χ^2 на однородность

$$X_1^c, \dots, X_{n_c}^c \sim iid F_c(t)$$

$$X_1^T, \dots, X_{n_T}^T \sim iid F_T(t)$$

	z_1	z_2	...	z_S
T	$\mathcal{V}_1$	$\mathcal{V}_2$	...	$\mathcal{V}_S$
C	w_1	w_2	...	w_S

$$H_0: F_T(t) = F_c(t)$$

$$H_A: \neq$$

COUNT(*)

$$\sum_{j=1}^S \frac{\left(\frac{\mathcal{V}_j}{n_T} - \frac{w_j}{n_c} \right)^2}{\frac{w_j}{n_c} \left(1 - \frac{w_j}{n_c} \right)} \underset{H_0}{\sim}^{asy} \chi_{S-1}^2$$

⑤ Тест χ^2 на кез. выборок и тест Фишера

$Y \backslash X$	и	т	
взяли	7	1	8
нет	1	11	12
	8	12	

H_0 : X и Y независимы

H_A : зависимы

$$P(X=x \cap Y=y) = P(X=x) \cdot P(Y=y)$$

$$\frac{\sum_i \sum_j [X_i=x \cap Y_j=y]}{n} = \frac{\sum_i [X_i=x]}{n} \cdot \frac{\sum_j [Y_j=y]}{n}$$

$$\frac{j_{ij}}{n} = \frac{j_{i.}}{n} \cdot \frac{j_{.j}}{n}$$

$$PF = \sum_{i,j} \frac{\left(n \left[\frac{j_{ij}}{n} - \frac{j_{i.}}{n} \cdot \frac{j_{.j}}{n} \right] \right)^2}{n \cdot \frac{j_{i.}}{n} \cdot \frac{j_{.j}}{n}} \underset{H_0}{\sim} \chi^2_{(k-1)(s-1)}$$

k - кол-во значений X

s - кол-во значений Y

1900-1915 Пирсон

$$PF \xrightarrow{d} \chi^2_{k-s-1}$$

1915-н.в. Фишер


$$PF \xrightarrow{d} \chi^2_{(k-1)(s-1)}$$

⑥ Тест Фишера (докус)

можно вычислить табличное p-е.

$$P(7 \text{ мут. и } 1 \text{ нем.}) = \frac{C_{20}^7 \cdot C_{20}^1}{C_{20}^8}$$

W - сколько взяли мутизм



$W_{1-\alpha}$

W_{obs}

Опр.

Критерий
Фишера

$$MV = \sup_{t_1, t_2} [\hat{F}(t_1, t_2) - \hat{F}(t_1) \cdot \hat{F}(t_2)] \sim_{H_0} ?$$

бутстрэппинг

$MV_{1-\alpha}$

vs

MV_{obs}